

Principe de l'algorithme de stitching de courbes SAS

1 Objectif général

Dans une expérience de diffusion aux petits angles, une même mesure peut être obtenue à partir de plusieurs configurations instrumentales et parfois de plusieurs détecteurs pour une même configuration. Chaque courbe fournit une mesure de l'intensité diffusée sur une gamme de vecteur de diffusion Q :

$$I(Q) \pm \Delta I(Q),$$

avec éventuellement une estimation de la résolution expérimentale :

$$\Delta Q(Q).$$

L'objectif du stitching est de construire une seule courbe finale continue, cohérente et exploitable à partir de plusieurs courbes partielles. L'algorithme ne doit cependant pas utiliser aveuglément toutes les courbes disponibles. Une courbe de grand angle, par exemple, peut être redondante si elle couvre une gamme de Q déjà mieux mesurée par une autre configuration.

Le principe général est donc le suivant :

sélectionner les segments utiles, les raccorder, puis concaténer

2 Notion de segment

L'algorithme ne raisonne pas seulement en termes de configuration instrumentale. Il considère chaque courbe détecteur comme un *segment candidat*. Un segment correspond donc typiquement à une combinaison :

configuration + détecteur.

Par exemple :

```
c9d0  ↔  config_9, detector0,
c10d0 ↔  config_10, detector0,
c10d2 ↔  config_10, detector2.
```

Chaque segment contient quatre colonnes :

$$Q, \quad I(Q), \quad \Delta I(Q), \quad \Delta Q(Q).$$

Pour chaque segment, on calcule aussi des informations globales :

$$Q_{\min}, \quad Q_{\max}, \quad N_{\text{points}},$$

ainsi que des indicateurs de qualité, par exemple :

$$\text{median} \left(\frac{\Delta I}{I} \right), \quad \text{median} \left(\frac{\Delta Q}{Q} \right).$$

3 Pourquoi ne pas concaténer toutes les courbes ?

Lorsque plusieurs détecteurs sont disponibles, il arrive que certains segments :

- recouvrent presque entièrement une zone déjà couverte par un autre segment ;
- aient une incertitude relative plus grande ;
- présentent une résolution moins favorable ;
- introduisent une discontinuité dans la courbe finale ;
- n'apportent pas de nouvelle gamme utile en Q .

Dans ce cas, inclure systématiquement tous les segments peut dégrader la courbe finale. L'algorithme doit donc être capable de rejeter un segment même si celui-ci est techniquement présent dans les fichiers d'entrée.

Le critère fondamental est :

un segment est utile seulement s'il apporte une information nouvelle et fiable

4 Raccord entre deux segments

Considérons deux segments A et B qui se recouvrent sur une gamme de Q . La question est de savoir si le segment B peut être raccordé au segment A par un simple facteur multiplicatif.

On cherche donc un facteur s tel que :

$$I_A(Q) \simeq s I_B(Q).$$

Cette convention est importante : le facteur s est le facteur qui transforme le segment B vers l'échelle du segment A .

4.1 Travail dans l'espace logarithmique

Plutôt que d'ajuster directement le rapport I_A/I_B , on travaille sur le log-ratio :

$$r(Q) = \ln I_A(Q) - \ln I_B(Q).$$

Si le raccord est purement multiplicatif, alors :

$$r(Q) \simeq \ln s.$$

Autrement dit, dans la zone de recouvrement, le log-ratio doit former un plateau. Le problème du raccord devient donc un problème de détection de plateau.

4.2 Incertitude sur le log-ratio

Si les incertitudes sur les deux intensités sont indépendantes, l'incertitude sur le log-ratio est approximativement :

$$\sigma_r^2(Q) = \left(\frac{\Delta I_A(Q)}{I_A(Q)} \right)^2 + \left(\frac{\Delta I_B(Q)}{I_B(Q)} \right)^2.$$

Cette quantité sert à pondérer les points dans la zone de recouvrement.

4.3 Estimation du facteur de raccord

Dans une fenêtre de recouvrement donnée Ω , on ajuste une constante :

$$r(Q) \simeq \ln s.$$

Le meilleur estimateur pondéré est :

$$\ln s = \frac{\sum_{i \in \Omega} w_i r_i}{\sum_{i \in \Omega} w_i}, \quad w_i = \frac{1}{\sigma_{r,i}^2}.$$

L'incertitude associée est :

$$\sigma_{\ln s} = \left(\sum_{i \in \Omega} w_i \right)^{-1/2}.$$

Le facteur multiplicatif est ensuite :

$$s = \exp(\ln s),$$

et son incertitude est approximativement :

$$\sigma_s \simeq s \sigma_{\ln s}.$$

5 Recherche automatique d'une bonne fenêtre de recouvrement

Le recouvrement géométrique complet entre deux segments n'est pas toujours la meilleure zone pour calculer le facteur. Les bords de détecteur, la résolution, le bruit ou des défauts de normalisation peuvent rendre une partie de l'overlap moins fiable.

L'algorithme teste donc plusieurs fenêtres candidates dans la zone de recouvrement. Pour chaque fenêtre, il calcule :

- le facteur de raccord s ;
- le χ^2 réduit du fit par une constante ;
- la pente résiduelle du log-ratio ;
- la largeur logarithmique de la fenêtre ;
- un indicateur de résolution relative.

5.1 Test de platitude

Un raccord acceptable doit présenter un log-ratio à peu près constant. Pour vérifier cela, on ajuste aussi :

$$r(Q) = a + b \ln Q.$$

La pente b doit être compatible avec zéro. On utilise donc le score :

$$z_b = \left| \frac{b}{\sigma_b} \right|.$$

Une valeur petite de z_b indique que la pente n'est pas significative. Une valeur grande indique que le ratio dérive avec Q , donc que la fenêtre ne correspond pas à un vrai plateau.

5.2 Rôle du χ^2

Le χ^2 réduit mesure la compatibilité du log-ratio avec une constante :

$$\chi_\nu^2 = \frac{1}{N-1} \sum_{i \in \Omega} \frac{(r_i - \ln s)^2}{\sigma_{r,i}^2}.$$

Un χ_ν^2 trop élevé indique que les fluctuations autour du plateau sont plus grandes que ce qui est attendu à partir des incertitudes.

Cependant, le χ^2 seul n'est pas suffisant : une dérive lente et régulière du ratio peut parfois donner un χ^2 acceptable si les incertitudes sont grandes. C'est pourquoi l'algorithme utilise aussi le critère de pente.

5.3 Indicateur de résolution

La résolution n'est pas utilisée pour corriger explicitement les courbes. L'algorithme ne déconvolue pas les données et ne dégrade pas une courbe pour imiter la résolution d'une autre.

En revanche, la résolution peut être utilisée comme critère de qualité secondaire. Pour une paire de segments A et B , on définit :

$$\rho_\Omega = \text{median}_{Q \in \Omega} \left[\sqrt{\left(\frac{\Delta Q_A}{Q}\right)^2 + \left(\frac{\Delta Q_B}{Q}\right)^2} \right].$$

Une fenêtre où ρ_Ω est plus faible est préférée, toutes choses égales par ailleurs.

5.4 Score d'une fenêtre

Chaque fenêtre candidate reçoit un score de la forme :

$$S_\Omega = \chi_{\nu,\Omega}^2 + \lambda_b \left(\frac{b_\Omega}{\sigma_{b,\Omega}} \right)^2 + \lambda_w \frac{\Delta \ln Q_{\text{total}}}{\Delta \ln Q_\Omega} + \lambda_Q \left(\frac{\rho_\Omega}{\rho_{\text{ref}}} \right)^2.$$

Les différents termes ont les rôles suivants :

χ_ν^2 pénalise les fenêtres qui ne sont pas compatibles avec un plateau.

Terme de pente pénalise les ratios qui dérivent avec Q .

Terme de largeur évite de choisir une fenêtre trop petite simplement parce qu'elle donne localement un bon score.

Terme de résolution favorise les fenêtres où la résolution relative combinée est meilleure.

La meilleure fenêtre est celle qui minimise ce score.

6 Grille de calcul du ratio

Deux segments n'ont pas nécessairement les mêmes valeurs de Q . Pour calculer le log-ratio, les intensités doivent donc être évaluées sur une même grille.

L'algorithme peut utiliser une grille commune logarithmique dans la zone de recouvrement :

$$Q_k = \exp \left[\ln Q_{\min} + k \frac{\ln Q_{\max} - \ln Q_{\min}}{N-1} \right].$$

Les deux courbes sont interpolées sur cette grille commune. Le nombre de points est choisi de manière conservatrice, typiquement :

$$N = \min(N_A, N_B),$$

où N_A et N_B sont les nombres de points réellement présents dans l'overlap pour les deux segments. Cela évite de sur-échantillonner artificiellement les données interpolées.

7 Sélection des segments utiles

Une fois que l'on sait tester le raccord entre deux segments, l'étape suivante consiste à construire une chaîne de segments.

L'algorithme part d'un segment initial, par exemple le segment de plus bas Q , puis cherche quel segment peut prolonger la courbe de la manière la plus pertinente.

Pour chaque candidat B à ajouter après un segment courant A , on calcule :

- la qualité du raccord $A \rightarrow B$;
- la qualité intrinsèque du segment B ;
- la nouvelle gamme de Q apportée par B .

La nouvelle couverture logarithmique est définie par :

$$\Delta \ln Q_{\text{new}} = \max \left[0, \ln \left(\frac{Q_{\text{max},B}}{Q_{\text{max},A}} \right) \right].$$

Un segment qui ne dépasse pas réellement la gamme déjà couverte n'apporte pas d'information nouvelle significative.

7.1 Qualité intrinsèque d'un segment

Pour un segment seul, on définit un score de qualité simple :

$$Q_{\text{seg}} = \text{median} \left[\left(\frac{\Delta I}{I} \right)^2 + \lambda_{\text{res}} \left(\frac{\Delta Q}{Q} \right)^2 \right].$$

Plus ce score est petit, meilleure est la qualité du segment.

7.2 Coût de transition

Pour choisir le prochain segment, l'algorithme minimise un coût de transition du type :

$$C(A \rightarrow B) = S_{A \rightarrow B} + \lambda_{\text{seg}} Q_{\text{seg},B} - \lambda_{\text{new}} \Delta \ln Q_{\text{new}}.$$

Le premier terme mesure la qualité du raccord. Le deuxième pénalise les segments bruités ou de mauvaise résolution. Le troisième favorise les segments qui étendent réellement la gamme de Q .

Ainsi, un segment est favorisé s'il :

1. se raccorde proprement au segment courant ;
2. possède une bonne qualité intrinsèque ;
3. apporte une nouvelle gamme de Q .

8 Critères d'acceptation et de rejet

Une transition entre deux segments est acceptée seulement si elle satisfait des critères minimaux :

$$\chi_{\nu}^2 < \chi_{\nu,\text{max}}^2,$$

$$\left| \frac{b}{\sigma_b} \right| < z_{b,\text{max}},$$

$$\Delta \ln Q_{\text{new}} > \Delta \ln Q_{\text{min}}.$$

Si l'une de ces conditions échoue, la transition est rejetée.

Les principaux statuts de rejet sont :

rejected_bad_overlap le ratio n'est pas suffisamment plat ou le χ^2 est trop élevé ;
rejected_no_new_q_coverage le segment n'apporte pas assez de nouvelle gamme en Q ;
rejected_redundant_or_no_new_q_coverage le segment est redondant par rapport à la chaîne déjà retenue ;
rejected_no_valid_transition aucun raccord acceptable n'a été trouvé pour intégrer ce segment.

Ce mécanisme est essentiel pour éviter d'ajouter automatiquement des détecteurs grand angle qui n'améliorent pas la courbe finale.

9 Construction de la courbe finale

Une fois la chaîne de segments retenue, chaque segment reçoit un facteur global. Si le premier segment a un facteur global $G_0 = 1$, et si la transition $A \rightarrow B$ donne un facteur $s_{B \rightarrow A}$, alors :

$$G_B = G_A s_{B \rightarrow A}.$$

La courbe corrigée du segment B est donc :

$$I_{B,\text{corr}}(Q) = G_B I_B(Q),$$

et son incertitude :

$$\Delta I_{B,\text{corr}}(Q) = G_B \Delta I_B(Q).$$

La résolution ΔQ n'est pas multipliée par ce facteur, car il s'agit d'une incertitude sur l'axe Q , pas sur l'intensité :

$$\Delta Q_{B,\text{corr}}(Q) = \Delta Q_B(Q).$$

9.1 Gestion des zones de recouvrement

Dans les zones de raccord, l'algorithme ne garde pas nécessairement tout l'overlap. Il conserve généralement une petite région autour de la fenêtre de fit pour éviter une coupure trop brutale, mais sans dupliquer excessivement les points.

Si la fenêtre de fit est :

$$[Q_{\text{fit,min}}, Q_{\text{fit,max}}],$$

on peut conserver une fraction centrale de cette fenêtre en échelle logarithmique. Cela permet de garder une transition visuellement et numériquement contrôlée.

10 Choix de l'échelle de référence

Par défaut, la courbe finale est exprimée dans l'échelle du premier segment retenu. Cependant, il est souvent préférable d'exprimer la courbe finale dans l'échelle d'une configuration de référence choisie par l'utilisateur.

Supposons que les facteurs globaux obtenus soient :

$$G_0, \quad G_1, \quad G_2, \dots$$

et que le segment de référence ait le facteur :

$$G_{\text{ref}}.$$

On renormalise alors tous les facteurs :

$$G_i^{\text{new}} = \frac{G_i}{G_{\text{ref}}}.$$

Ainsi, le segment de référence a bien :

$$G_{\text{ref}}^{\text{new}} = 1.$$

Cette opération ne change pas la sélection des segments ni la qualité des raccords. Elle change seulement l'échelle absolue de la courbe finale.

11 Résumé de l'algorithme

L'algorithme complet peut être résumé ainsi :

1. Charger toutes les courbes disponibles.
2. Transformer chaque courbe détecteur en segment candidat.
3. Calculer les indicateurs de qualité de chaque segment.
4. Tester les raccords possibles entre paires de segments.
5. Pour chaque raccord, chercher la meilleure fenêtre de plateau du log-ratio.
6. Rejeter les transitions qui ne sont pas assez plates, trop bruitées ou sans nouvelle couverture en Q .
7. Construire progressivement une chaîne de segments utiles.
8. Rejeter les segments redondants ou non raccordables.
9. Calculer les facteurs globaux de chaque segment retenu.
10. Renormaliser éventuellement la courbe sur une configuration de référence.
11. Concaténer les segments retenus pour produire la courbe finale.

12 Points importants à retenir

- Le raccord est basé sur un facteur multiplicatif entre segments.
- Ce facteur est estimé à partir d'un plateau du log-ratio.
- Le χ^2 seul ne suffit pas ; il faut aussi contrôler la pente du log-ratio.
- La résolution ΔQ n'est pas utilisée pour corriger explicitement les courbes, mais elle peut aider à choisir les meilleures fenêtres.
- Tous les détecteurs ne sont pas nécessairement utilisés.
- Un segment peut être rejeté simplement parce qu'il est redondant.
- La configuration de référence fixe l'échelle finale, mais ne change pas la sélection des segments.

13 Interprétation pratique

Une bonne courbe finale n'est pas celle qui contient le plus grand nombre de points, mais celle qui utilise les points les plus fiables et les plus utiles. L'algorithme cherche donc un compromis entre continuité, qualité statistique, résolution et couverture en Q .

Dans ce cadre, le stitching n'est pas seulement une opération de collage. C'est une étape de sélection raisonnée de l'information expérimentale.

stitching = raccord multiplicatif + contrôle de qualité + sélection des segments utiles